

STOKASTİK OPTİMİZASYON VE VARYASYONEL ÇIKARIM İLE ÜRETKEN MODELLEME: VAE'LERİN MATEMATİKSEL TEMELLERİ

**C. Doersch'in "Tutorial on Variational Autoencoders" (2021) makalesine dayalı
inceleme raporu*

Mohammed Izedin Mohammed
Yapay Zekanın Matematiksel Temelleri Dersi

Özet: Bu rapor, Carl Doersch'ün "Tutorial on Variational Autoencoders" (2021 revizyonu) başlıklı makalesi temel alınarak hazırlanmıştır. Çalışma, üretken modellemedeki temel zorluk olan "hesaplanamaz integral" problemini ele almakta ve bu problemin Varyasyonel Çıkarım ile Kanıt Alt Sınırı (ELBO) türetimi kullanılarak nasıl bir optimizasyon problemine dönüştürüldüğünü incelemektedir. Ayrıca, modelin stokastik gradyan inişi (SGD) ile eğitilebilmesini sağlayan "Yeniden Parametrelendirme Hilesi" (Reparameterization Trick) matematiksel olarak açıklanmıştır.

Anahtar Kelimeler: Varyasyonel Otokodlayıcılar, ELBO, Stokastik Optimizasyon, Reparameterization Trick, KL İraksaması.

1. GİRİŞ: ÜRETKEN MODELLEME PROBLEMİ

Makine öğrenmesinde temel amacımız, veri noktaları X üzerinde tanımlı $P(X)$ olasılık dağılımını modelleyerek yeni örnekler üretmektir. Bu süreçte, verinin gözlemlenemeyen bir z değişkeni tarafından üretildiğini varsayan "Gizli Değişken Modelleri" kullanılır.

Bu modellerde verinin marjinal olabilirliğini (marginal likelihood) hesaplamak için şu integrali çözmemiz gerekir:

$$P(X) = \int P(X|z; \theta)P(z)dz \quad (1)$$

Burada $P(z)$ önsel (prior) dağılımdır. Bu integral yüksek boyutlu uzaylarda **hesaplanamaz** durumdadır. Çünkü tüm olası z değerleri üzerinden integrasyon almak, işlem yükü açısından imkansızdır ve gerçek sonsal dağılım $P(z|X)$ bilinmemektedir [1].

2. VARYASYONEL ÇIKARIM VE ELBO TÜRETİMİ

İntegrali doğrudan hesaplayamadığımız için, problemi bir optimizasyon problemine dönüştüren **Varyasyonel Çıkarım** yöntemini kullanırız. Bu yöntemde, bilinmeyen $P(z|X)$ dağılımına yaklaşayan parametrik bir $Q(z|X)$ dağılımı (Encoder) tanımlanır.

Amacımız, bu iki dağılım arasındaki farkı minimize etmektir. Bu farkı ölçmek için Kullback-Leibler (KL) İraksaması kullanılır:

$$\mathcal{D}_{KL}(Q(z|X)||P(z|X)) = \mathbb{E}_{z \sim Q}[\log Q(z|X) - \log P(z|X)] \quad (2)$$

Bayes kuralı uygulanıp, $\log P(X)$ terimi z 'den bağımsız olduğu için dışarı alındığında ve terimler yeniden düzenlendiğinde, optimizasyon hedefimiz olan **Kanıt Alt Sınırı (Evidence Lower Bound - ELBO)** elde edilir:

$$\log P(X) - \mathcal{D}_{KL}(Q||P) = \mathbb{E}_Q[\log P(X|z)] - \mathcal{D}_{KL}(Q(z|X)||P(z)) \quad (3)$$

KL ıraksaması her zaman negatif olmayan bir değer olduğundan ($\mathcal{D}_{KL} \geq 0$), sağ taraftaki ifade log-olabilirlik için bir alt sınırdır:

$$\log P(X) \geq \text{ELBO}$$

Bu sonuç, entegrasyon probleminin başarıyla bir optimizasyon problemine dönüştürüldüğünü kanıtlar [1].

3. OPTİMİZASYON HEDEFİNİN YORUMLANMASI

Maksimize edilecek ELBO denklemi, sınır ağının minimize etmesi gereken bir kayıp fonksiyonu olarak şu şekilde ifade edilir:

$$\mathcal{L}(\theta, \phi) = \underbrace{-\mathbb{E}_{z \sim Q_\phi}[\log P_\theta(X|z)]}_{\text{Reconstruction}} + \underbrace{\mathcal{D}_{KL}(Q_\phi(z|X) || P(z))}_{\text{Regularization}} \quad (4)$$

Bu yapı, **kısıtlı optimizasyon** (constrained optimization) prensibine dayanır:

- **1. Yeniden Oluşturma (Reconstruction):** Veriyi gizli uzaydan ne kadar iyi geri oluşturabildiğimizi ölçer. Veriye sadakati (fidelity) temsil eder.
- **2. Düzenleştirme (Regularization):** Öğrenilen gizli uzayın, önsel dağılımımız olan Standart Normal Dağılım ($\mathcal{N}(0, I)$) ile ne kadar eşleştiğini ölçer. Bu terim, modelin aşırı öğrenmesini (overfitting) engelleyen bir ceza (penalty) görevi görür.

4. STOKASTİK GRADYAN VE YENİDEN PARAMETRELENDİRME

Teorik hedef belirlenmiş olsa da, modelin eğitimi sırasında pratik bir engel ortaya çıkar. Eğitim için kullanılan Geri Yayılım (Backpropagation) algoritması, türevlenebilir işlemlere ihtiyaç duyar. Ancak, ağın içindeki örnekleme işlemi ($z \sim \mathcal{N}(\mu, \sigma^2)$) stokastik olduğu için türevlenemez. Bu durum, gradyan akışını durdurur.

Bu sorunu çözmek için, **Yeniden Parametrelendirme Hilesi** kullanılır. Rastgelelik, sistemin parametrelerinden ayrılarak harici bir gürültü değişkenine (ϵ) taşınır:

$$z = \mu(X) + \sigma(X) \odot \epsilon, \quad \text{burada } \epsilon \sim \mathcal{N}(0, I) \quad (5)$$

Bu koordinat dönüşümü sayesinde z ; μ ve σ parametrelerinin deterministik bir fonksiyonu haline gelir. Böylece $\frac{\partial z}{\partial \mu}$ ve $\frac{\partial z}{\partial \sigma}$ türevleri hesaplanabilir hale gelir ve model uçtan uca eğitilebilir [1].

5. GAUSSIAN ÖNSEL DAĞILIMIN AVANTAJI

Önsel (Prior) ve sonsal (Posterior) dağılımlar için Gaussian kullanmanın temel avantajı, KL İraksaması teriminin analitik (kapalı form) bir çözümünün olmasıdır:

$$\mathcal{D}_{KL} = -\frac{1}{2} \sum_{j=1}^J (1 + \log(\sigma_j^2) - \mu_j^2 - \sigma_j^2)$$

Bu formül sayesinde, düzenleme terimi için simülasyon yapmaya gerek kalmaz, eğitim hızı artar ve varyans düşer.

6. SONUÇ

Bu çalışmada, VAE'lerin matematiksel altyapısı açıklanmıştır. VAE'ler; hesaplanamaz bir integrali ELBO kullanarak çözülebilir bir optimizasyon problemine dönüştürmesi ve türevlenemeyen örnekleme işlemini Yeniden Parametrelendirme Hilesi ile aşması sayesinde, modern üretken yapay zekanın temel taşlarından biri olmuştur.

Referanslar

[1] C. Doersch, "Tutorial on Variational Autoencoders," arXiv preprint arXiv:1606.05908, 2016 (revised 2021).